Creado por:

Isabel Maniega

JSON / XML con Python

Módulo Json

JSON se ha convertido en el estándar por defecto para el intercambio de información. Sus usos son:

- · Transportar datos Tal vez esté
- · Recopilando información a través de una API
- Almacenando sus datos en una base de datos de documentos.

Las siglas vienen de:

- Java...
- · ...Script
- Object
- Notation

JSON es la respuesta a una necesidad bastante básica: la necesidad de transferir datos que son el contenido de un objeto o un conjunto de objetos. El mecanismo que la soluciona debe ser portable e independiente de la plataforma.

¿Cómo podemos satisfacer tal requisito?

El problema con el que nos enfrentamos es cómo representar un objeto (entendido como un conjunto de datos de diferentes tipos, incluidos otros objetos) o incluso un único valor de forma que pueda sobrevivir a las transferencias de red y las conversiones entre plataformas.

JSON resuelve el problema con dos trucos simples:

- utiliza texto codificado en UTF-8, lo que significa que no se utilizan formatos dependientes de la máquina o la plataforma; también significa que los datos que lleva JSON son legibles (mal, pero siempre legibles) y comprensibles para los humanos;
- utiliza un formato simple y no muy expandido (podemos llamarlo sintaxis, o incluso gramática) para representar dependencias mutuas y relaciones entre diferentes partes de los objetos, y es capaz de transferir no solo los valores de las propiedades de los objetos, sino también sus nombres.

En JSON, puede ser un valor sin nombre como un número, una cadena, un booleano o... nada, aunque esto no es lo que más nos gusta de JSON. JSON es capaz de transportar datos mucho más complejos, recopilados y agregados en compuestos más grandes.

Si desea transferir no solo datos sin procesar, sino también todos los nombres asociados a ellos (como la forma en que los objetos mantienen sus propiedades), JSON ofrece una sintaxis que parece un pariente cercano del diccionario de Python, que es, de hecho, un conjunto de pares clave:valor. Hacer tal suposición nos lleva a la siguiente pregunta: ¿podemos usar la sintaxis de Python para codificar y decodificar mensajes de red en REST?

Para poder manejar estos datos usaremos el modulo json:

```
import json
```

Concepto básico:

}

- **Serialización:** Consiste en convertir un objeto de Python (normalmente una lista o diccionario) en un string.
- **Deserialización:** Consiste en convertir un string en un objeto de Python (normalmente una lista o diccionario).

```
In [1]: # Ejemplo de serialización
import json

data = {
    "presidente": {
```

```
"nombre": "Zaphod Beeblebrox",
                 "especie": "Betelgeusian"
             }
         }
         json string = json.dumps(data)
         json string
 Out[1]: '{"presidente": {"nombre": "Zaphod Beeblebrox", "especie": "Betelgeusia
         n"}}'
 In [2]: type(json string)
 Out[2]: str
 In [3]: json_string["presidente"]
         # TypeError: string indices must be integers
         # No podemos recorrerlo para ello será necesario decodificarlo
                                                  Traceback (most recent call las
        TypeError
        t)
        Cell In[3], line 1
        ----> 1 json string["presidente"]
              3 # TypeError: string indices must be integers
              4 # No podemos recorrerlo para ello será necesario decodificarlo
       TypeError: string indices must be integers
 In [4]: # La opción de dumps nos sirve para escribirlo en un archivo de formato J
         with open("archivo_data.json", "w") as write_file:
             json.dump(data, write file)
 In [5]: # Indent nos permite añadir un salto a cada componente del Json:
         with open("archivo data.json", "w") as write file:
             json.dump(data, write file, indent=2)
In [12]: # sort keys= True: la salida de los diccionarios se ordenará por clave:
         # Salida esperada: {"age": 30, "city": "New York", "name": "John"}
         data = {
           "name": "John",
           "age": 30,
           "city": "New York"
         with open("archivo_data.json", "w") as write_file:
             json.dump(data, write_file, indent=2, sort_keys=True)
 In [7]: # Ejemplo de deserialización
         # Convertir datos codificados en JSON en objetos de Python.
         json_decoded = json.loads(json_string)
         json_decoded
```

Como puede ver, Python utiliza un pequeño conjunto de reglas simples para crear mensajes JSON a partir de sus datos nativos. Aquí está:

Python data	JSON element
dict	object
list or tuple	array
string	string
int or float	number
True / False	true / false
None	null

Pero hasta ahora parece simple y coherente, pero ¿dónde está la trampa?

La trampa está aquí:

```
import json

class Who:
    def __init__(self, name, age):
        self.name = name
        self.age = age

some_man = Who('John Doe', 42)
print(json.dumps(some_man))
```

El resultado que verás es extremadamente decepcionante:

```
TypeError: Object of type 'Class' is not JSON serializable
```

Sí, esa es la clave. No puedes simplemente volcar el contenido de un objeto, incluso un objeto tan simple como este.

Por supuesto, si no necesitas nada más que un conjunto de propiedades de objeto y sus valores, puedes realizar un truco (un poco sucio) y volcar no el objeto en sí, sino el contenido de su propiedad dict. Funcionará, pero esperamos más.

¿Qué deberíamos hacer?

Un enfoque se basa en el hecho de que la serialización se realiza mediante el método denominado default(), que forma parte de la clase json. JSONEncoder. Te da la oportunidad de sobrecargar el método que define una subclase de JSONEncoder y pasarlo a dumps().

Pero, ¿qué sucede con los objetos de Python? ¿Podemos deserializarlos de la misma manera que realizamos la serialización?

Como probablemente esperes, deserializar un objeto puede requerir algunos pasos adicionales. Sí, de hecho. Como loads() no puede adivinar qué objeto (de qué clase) necesitas deserializar, debes proporcionar esta información.

Observa el fragmento que hemos proporcionado en la ventana del editor.

Como puedes ver, hay un argumento de palabra clave llamado object_hook, que se usa para señalar la función responsable de crear un objeto nuevo de una clase necesaria y de llenarlo con datos reales.

Nota: la función decode_who() recibe una entidad de Python, o más específicamente, un diccionario. Como el constructor de Who espera dos valores ordinarios, una cadena y un número, no un diccionario, tenemos que usar un pequeño truco: hemos empleado el operador doble * para convertir el directorio en una lista de argumentos de palabras clave construida a partir de los pares key:value del diccionario. Por supuesto, las claves del diccionario deben tener los mismos nombres que los parámetros del constructor.

Nota: la función, especificada por object_hook se invocará solo cuando la cadena JSON describa un objeto JSON. Lo sentimos, no hay excepciones a esta regla.

```
In [13]: import json

class Who:
    def __init__(self, name, age):
        self.name = name
        self.age = age

def encode_who(w):
    if isinstance(w, Who):
        return w.__dict__
    else:
        raise TypeError(w.__class__.__name__ + 'is not JSON serializable'

def decode_who(w):
    return Who(w['name'], w['age'])
```

```
old_man = Who("Jane Doe", 23)
json_str = json.dumps(old_man, default=encode_who)
new_man = json.loads(json_str, object_hook=decode_who)
print(type(new_man))
print(new_man.__dict__)
```

```
<class '__main__.Who'>
{'name': 'Jane Doe', 'age': 23}
```

Como ya se ha dicho, también es posible utilizar un enfoque más puro basado en objetos, que se basa en la redefinición de la clase JSONDecoder. Lamentablemente, esta variante es más complicada que su contraparte de codificación.

No necesitamos reescribir ningún método, pero sí tenemos que redefinir el constructor de la superclase, lo que hace que nuestro trabajo sea un poco más laborioso. El nuevo constructor tiene como objetivo hacer solo una cosa: establecer una función para la creación de objetos.

Como puede ver, esto es exactamente lo mismo que hicimos antes, pero expresado en un nivel diferente.

Nos complace informarle que ahora hemos reunido suficiente conocimiento para pasar al siguiente nivel. Volveremos a tratar algunos problemas de red, pero también queremos mostrarle algunas herramientas nuevas y útiles.

```
In [14]: import json
         class Who:
             def init (self, name, age):
                 self.name = name
                 self.age = age
         class MyEncoder(json.JSONEncoder):
             def default(self, w):
                 if isinstance(w, Who):
                     return w. dict
                 else:
                     return super().default(self, z)
         class MyDecoder(json.JSONDecoder):
             def init (self):
                 json.JSONDecoder.__init__(self, object_hook=self.decode_who)
             def decode_who(self, d):
                 return Who(**d)
         some man = Who('Jane Doe', 23)
         json str = json.dumps(some man, cls=MyEncoder)
         new_man = json.loads(json_str, cls=MyDecoder)
```

```
print(type(new_man))
print(new_man.__dict__)

<class '__main__.Who'>
{'name': 'Jane Doe', 'age': 23}
```

Archivos XML

Procesamiento de XML en Python

Python se utiliza habitualmente para procesar distintos tipos de datos. Tal vez, mientras trabaja como programador, tenga que leer o crear un archivo de datos en formato XML. Pronto, hacerlo será pan comido.

La biblioteca estándar de Python ofrece algunos módulos interesantes para trabajar con XML:

- xml.etree.ElementTree: tiene una API muy simple para analizar y crear datos XML.
 Es una excelente opción para personas que nunca han trabajado con el Modelo de objetos de documento (DOM) antes.
- xml.dom.minidom: es la implementación mínima del Modelo de objetos de documento (DOM). Al utilizar el DOM, el enfoque para un documento XML es ligeramente diferente, porque se analiza en una estructura de árbol en la que cada nodo es un objeto.
- xml.sax: SAX es un acrónimo de "Simple API for XML". SAX es una interfaz en
 Python para el análisis de documentos XML impulsado por eventos. A diferencia de
 los módulos anteriores, analizar un documento XML simple utilizando este módulo
 requiere más trabajo.

En este curso aprenderás a crear y procesar documentos XML utilizando el módulo xml.etree.ElementTree. No perdamos más tiempo. ¡Vamos allá!

¿Qué es XML?

Extensible Markup Language (XML) es un lenguaje de marcado diseñado para almacenar y transportar datos, por ejemplo, mediante sistemas que utilizan el protocolo de comunicación SOAP. Una de sus principales ventajas es la capacidad de definir sus propias etiquetas que hacen que el documento sea más legible para los humanos. XML es un estándar recomendado por la organización W3C. Veamos qué elementos contienen los documentos XML:

- prólogo: la primera línea (opcional) del documento. En el prólogo, puede especificar la codificación de caracteres, por ejemplo, <?xml version="1.0" encoding="ISO-8859-2"?> cambia la codificación de caracteres predeterminada (UTF-8) a ISO-8859-2.
- elemento raíz: el documento XML debe tener un elemento raíz que contenga todos los demás elementos. En el ejemplo siguiente, el elemento principal es la etiqueta data.

- elementos: consisten en etiquetas de apertura y cierre. Los elementos incluyen texto, atributos y otros elementos secundarios. En el ejemplo siguiente, podemos encontrar el elemento book con el atributo title y dos elementos secundarios (author y year).
- atributos: estos se colocan en las etiquetas de apertura. Consisten en pares clavevalor, p. ej., title = "El Principito".

NOTA: Cada etiqueta XML abierta debe tener una etiqueta closing correspondiente.

Análisis de XML (parte 1)

Procesar archivos XML en Python es muy fácil gracias a la clase ElementTree proporcionada por el módulo xml.etree.ElementTree . El objeto ElementTree es responsable de presentar el documento XML en forma de árbol en el que podemos movernos hacia arriba o hacia abajo.

Primero, necesitamos importar el módulo apropiado y definir un alias para él. Es común usar el alias ET, pero por supuesto puedes darle el nombre que quieras. Para crear un árbol (un objeto ElementTree) a partir de un documento XML existente, pásalo al método parse de la siguiente manera:

```
import xml.etree.ElementTree as ET
tree = ET.parse('books.xml')
root = tree.getroot()
```

El método getroot retorna el elemento raíz. Con acceso al elemento raíz, podemos llegar a cualquier elemento del documento. Cada uno de estos elementos está representado por una clase llamada Element.

Además del método parse, podemos utilizar el método llamado fromstring, que, como argumento, toma XML como cadena:

```
import xml.etree.ElementTree as ET
root = ET.fromstring(your_xml_as_string)
```

NOTA: El método fromstring no devuelve el objeto ElementTree , sino que devuelve el elemento raíz representado por la clase Element .

XML parsing (part 2)

Ya sabes cómo acceder al elemento raíz. Vamos a usarlo para visitar los elementos de nuestro árbol: mira el código en el editor.

Resultado:

```
The root tag is: data
The root has the following children:
book {'title': 'The Little Prince'}
book {'title': 'Hamlet'}
```

El elemento raíz y todos sus elementos secundarios son objetos Element . En el ejemplo anterior, utilizamos las siguientes propiedades:

- tag: devuelve el nombre de la etiqueta como una cadena
- attrib: devuelve todos los atributos de la etiqueta como un diccionario. Para recuperar el valor de un solo atributo, utilice su clave, p. ej., child.attrib ['title'].

```
In [15]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
print('The root tag is:', root.tag)
print('The root has the following children:')
for child in root:
    print(child.tag, child.attrib)
```

```
The root tag is: data
The root has the following children:
book {'title': 'The Little Prince'}
book {'title': 'Hamlet'}
```

Análisis XML (parte 3)

Además de iterar sobre los elementos del árbol, podemos acceder a ellos directamente mediante índices. Observa el ejemplo siguiente en el que utilizamos el elemento book actual para recuperar texto de sus elementos secundarios. Observa el código en el editor.

Resultado:

My books:

Title: The Little Prince

Author: Antoine de Saint-Exupéry

Year: 1943

Title: Hamlet

Author: William Shakespeare

Year: 1603

Durante cada iteración, hacemos referencia a los elementos secundarios del elemento book mediante índices. El índice 0 hace referencia al primer elemento secundario del elemento book, mientras que el índice 1 hace referencia a su segundo elemento secundario. La visualización de texto es posible gracias a la propiedad text, disponible en el objeto Element.

NOTA: Los índices también se utilizan en anidamientos más profundos, por ejemplo, root [0] [0] .text devuelve el primer elemento del libro y luego muestra el texto ubicado en su primer elemento secundario.

```
In [16]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
print("My books:\n")
for book in root:
    print('Title: ', book.attrib['title'])
    print('Author:', book[0].text)
    print('Year: ', book[1].text, '\n')
```

My books:

Title: The Little Prince

Author: Antoine de Saint-Exupéry

Year: 1943

Title: Hamlet

Author: William Shakespeare

Year: 1603

Análisis de XML (parte 4)

El módulo xml.etree.ElementTree, o más precisamente, la clase Element, proporciona varios métodos útiles para buscar elementos en un documento XML. Comencemos con el método llamado iter.

El método iter devuelve todos los elementos al pasar la etiqueta como argumento. El elemento que lo llama se trata como el elemento principal desde el que comienza la búsqueda. Para encontrar todas las coincidencias, el iterador itera recursivamente a través de todos los elementos secundarios y sus elementos anidados.

Observe el código en el editor para ver un ejemplo de una búsqueda de todos los elementos con la etiqueta author.

Resultado:

Antoine de Saint-Exupéry William Shakespeare

```
In [17]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
```

```
for author in root.iter('author'):
    print(author.text)
```

Antoine de Saint-Exupéry William Shakespeare

Análisis XML (parte 5)

El objeto Element tiene un método llamado findall para buscar elementos secundarios directos. A diferencia del método iter, el método findall solo busca los elementos secundarios en el primer nivel de anidación. Eche un vistazo al ejemplo en el editor.

El ejemplo no devuelve ningún resultado, porque el método **findall** solo puede iterar sobre los elementos del libro que son los elementos secundarios más cercanos del elemento raíz. El código correcto se ve así:

```
import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
for book in root.findall('book'):
    print(book.get('title'))
```

Resultado:

```
The Little Prince Hamlet
```

Para visualizar el valor de los atributos title, utilizamos el método get, que luce mucho mejor que una llamada book.attrib['title']. Su uso es muy sencillo: solo hay que introducir el nombre del atributo y opcionalmente (como segundo argumento) el valor que se devolverá si no se encuentra el atributo (por defecto es None).

NOTA: El método findall también acepta una expresión XPath. Te animamos a que profundices en el conocimiento de las expresiones XPath y lo apliques al ejemplo mostrado.

```
In [18]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
for book in root.findall('book'):
    print(book.get('title'))
```

The Little Prince Hamlet

Análisis de XML (parte 6)

Otro método útil que se utiliza para analizar un documento XML es un método llamado find . El método find devuelve el primer elemento secundario que contiene la

etiqueta especificada o la expresión XPath correspondiente. Observa el código en el editor.

Resultado:

```
The Little Prince
```

En el ejemplo, utilizamos el método find para encontrar el primer elemento secundario que contiene la etiqueta book y luego mostramos el valor de su atributo title. Ten en cuenta que el elemento desde el que iniciamos la búsqueda es el elemento raíz.

```
In [19]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
print(root.find('book').get('title'))
```

The Little Prince

Modificación de un documento XML (parte 1)

Ya aprendiste a analizar un documento XML. Es hora de dar el siguiente paso. Modifiquemos el árbol de elementos y creemos un nuevo archivo XML basado en él con los siguientes datos de la película:

¿Te preguntas si será difícil convertir datos de libros en datos de películas? Gracias al módulo xml.etree.ElementTree , es muy fácil.

Para cambiar la etiqueta del objeto Element, debemos asignar un nuevo valor a su propiedad tag. Observa el código en el editor.

Resultado:

```
movie {'title': 'The Little Prince'}
author : Antoine de Saint-Exupéry
year : 1943
movie {'title': 'Hamlet'}
author : William Shakespeare
year : 1603
```

En el ejemplo, durante cada iteración a través de los elementos book , los reemplazamos con la etiqueta movie y luego nos aseguramos de que todos los cambios se hayan realizado correctamente.

Modificación de un documento XML (parte 2)

Nuestro XML tiene algunos elementos innecesarios, como el autor y el año. Para eliminarlos, necesitamos utilizar el método llamado remove , proporcionado por la clase Element . Observa el código en el editor.

Resultado:

```
movie {'title': 'The Little Prince'}
movie {'title': 'Hamlet'}
```

El método remove elimina el elemento secundario que se pasa como argumento, que debe ser un objeto Element. Ten en cuenta que para este propósito usamos el método llamado find, con el que ya estás familiarizado.

```
In [21]: import xml.etree.ElementTree as ET

    tree = ET.parse('books.xml')
    root = tree.getroot()
    for child in root:
        child.tag = 'movie'
        child.remove(child.find('author'))
        child.remove(child.find('year'))
        print(child.tag, child.attrib)
        for sub_child in child:
             print(sub_child.tag, ':', sub_child.text)

movie {'title': 'The Little Prince'}
    movie {'title': 'Hamlet'}
```

Modificación de un documento XML (parte 3)

¿Recuerdas el método get que obtiene el valor del atributo? El objeto Element también tiene un método llamado set , que permite configurar cualquier atributo. Observa el código en el editor.

Resultado:

```
movie {'title': 'The Little Prince', 'rate': '5'}
movie {'title': 'Hamlet', 'rate': '5'}
```

El método set toma como argumentos el atributo nombre y su valor. En nuestro caso, lo utilizamos para establecer la calificación más alta para cada una de las películas.

```
In [22]: import xml.etree.ElementTree as ET

tree = ET.parse('books.xml')
root = tree.getroot()
for child in root:
    child.tag = 'movie'
    child.remove(child.find('author'))
    child.remove(child.find('year'))
    child.set('rate', '5')
    print(child.tag, child.attrib)
    for sub_child in child:
        print(sub_child.tag, ':', sub_child.text)

movie {'title': 'The Little Prince', 'rate': '5'}
movie {'title': 'Hamlet', 'rate': '5'}
```

Modificación de un documento XML (parte 4)

Debes haber notado que el documento XML modificado no se guarda en ningún lugar. Para guardar todos los cambios que hemos realizado en el árbol, tenemos que utilizar el método llamado write.

El método write tiene un solo argumento obligatorio, que es un nombre de archivo del archivo XML de salida, o un objeto de archivo abierto para escritura. Además, podemos definir la codificación de caracteres utilizando el segundo argumento (el valor predeterminado es US-ASCII). Para agregar un prólogo a nuestro documento, debemos pasar True en el tercer argumento.

Observa el ejemplo en el editor, en el que guardamos el árbol modificado en un archivo llamado movies.xml .

El archivo creado se ve así:

```
<?xml version='1.0' encoding='UTF-8'?>
<data><movie rate="5" title="The Little Prince" /><movie
rate="5" title="Hamlet" /></data>
```

```
print(sub_child.tag, ':', sub_child.text)

tree.write('movies.xml', 'UTF-8', True)

movie {'title': 'The Little Prince', 'rate': '5'}
movie {'title': 'Hamlet', 'rate': '5'}
```

Creación de un documento XML (parte 1)

Durante este curso, no ha tenido la oportunidad de crear un objeto Element . Veamos cómo crear un documento XML en Python.

El constructor de la clase Element toma dos argumentos. El primero es el nombre de la etiqueta que se creará, mientras que el segundo (opcional) es el diccionario de atributos. En el ejemplo del editor, hemos creado el elemento raíz representado por una etiqueta de datos sin atributos; observe el código.

Resultado:

```
<data />
```

En el ejemplo anterior, utilizamos el método dump, que nos permite depurar todo el árbol o un solo elemento.

```
In [24]: import xml.etree.ElementTree as ET
    root = ET.Element('data')
    ET.dump(root)
<data />
```

Creación de un documento XML (parte 2)

Además de la clase Element, el módulo xml.etree.ElementTree ofrece una función para crear elementos secundarios llamada SubElement. La función SubElement toma tres argumentos.

El primero define el elemento principal, el segundo define el nombre de la etiqueta y el tercero (opcional) define los atributos del elemento. Veamos cómo se ve en acción y analicemos el código en el editor.

Resultado:

```
<data><movie rate="5" title="The Little Prince" /><movie
rate="5" title="Hamlet" /></data>
```

En el ejemplo, hemos añadido dos elementos secundarios llamados movie al elemento root . Los elementos creados son objetos de la clase Element , por lo que podemos utilizar todos los métodos que aprendimos durante este curso.

NOTA: Para guardar un documento utilizando el método write, necesitamos tener un objeto ElementTree. Para ello, pasa nuestro elemento raíz a su constructor:

```
tree = ET.ElementTree(root)
```

```
In [25]: import xml.etree.ElementTree as ET

root = ET.Element('data')
movie_1 = ET.SubElement(root, 'movie', {'title': 'The Little Prince', 'ra
movie_2 = ET.SubElement(root, 'movie', {'title': 'Hamlet', 'rate': '5'})
ET.dump(root)

<data><movie title="The Little Prince" rate="5" /><movie title="Hamlet" ra
te="5" /></data>

Creado por:

Isabel Maniega
```